

Analyse des Tsunamis Historiques

Dataset NOAA — 2 259 événements | 330 av. J-C → 2020

Membres : Milena Malou (Leader) - Jean-Eudes Wandji – Yobe Gnadame

Data Analysis — MACSIN4A2225 | Hugo ALATRISTA-SALAS

Plan de la présentation

01

Le dataset

Présentation & dimensions multidimensionnelles

02

Exploration

Qualité des données, statistiques descriptives

03

Indicateur 1

Groupement — Top pays touchés

04

Indicateur 2

Pattern Mining — Règles d'association (Apriori)

05

Indicateur 3

Temporel — Évolution & prévision par décennie

06

Indicateur 4

Spatial — Clustering DBSCAN & carte mondiale

07

Dashboard & Demo

Python Dash — Visualisation interactive

Le Dataset

Tsunami Historical Data — NOAA / Kaggle

2 259

événements tsunamigènes

21

colonnes d'attributs

330 av. J-C
→ 2020

période couverte

Un dataset multidimensionnel :



Temporelle

YEAR, MONTH, DAY, HOUR, MINUTE
Quand l'événement s'est produit



Spatiale

LATITUDE, LONGITUDE, COUNTRY,
REGION
Où l'événement s'est produit



Analytique


CAUSE, EQ_MAGNITUDE, DEATHS,
DAMAGE
Caractéristiques de l'événement

Exploration des Données

Colonne clé	Type	% manquant	Plage / Valeurs
YEAR	int	0 %	-330 à 2020
MONTH	float	14 %	1 à 12
LATITUDE	float	4 %	
LONGITUDE	float	4 %	
CAUSE	object	2 %	Earthquake, Volcano, Landslide...
EQ_MAGNITUDE	float	42 %	0 à 9.5
DAMAGE_TOTAL	float	67 %	0 à 300 000 (milliers \$)
DEATHS_TOTAL	float	69 %	0 à 227 898

⚠ Les données avant 1800 présentent plus de valeurs manquantes — normal pour des données historiques, justifié dans le notebook.

Top 10 des pays les plus touchés par des tsunamis confirmés



Interprétation

JP Japon

Dominant — ceinture de feu du Pacifique



Pacifique

Concentre la majorité des événements

Méthode :

```
groupby('COUNTRY')  
.size()  
.sort_values()  
.head(10)
```

Règles d'association — Algorithme Apriori



Paramètres utilisés :

- **Support minimum** : 0.05 (5% des transactions)
- **Confiance minimum** : 0.40 (40% de fiabilité)
- **Tri des règles par lift** (> 1 = association non-aléatoire)


Exemple de règle trouvée :

Earthquake + Pacific → Damage Extreme

Support : 0.08 | Confiance : 0.71 | **Lift : 2.3**

→ Un séisme en zone Pacifique produit des dégâts extrêmes 2.3x plus souvent que le hasard

Évolution par décennie & prévision (depuis 1800)



Méthode

1. Filtrage :
Tsunamis confirmés
 ≥ 1800

2. Groupement :
 $\text{YEAR} // 10 * 10$
(décennie)

3. Prévision :
Régression
polynomiale
(degré 2)

* Barres orange
= prévision

Clustering DBSCAN — Identification des zones à risque

Pourquoi DBSCAN ?

- ✓ Pas besoin de définir le nombre de clusters à l'avance
- ✓ Détecte les points isolés (bruit = événements rares)
- ✓ Adapté aux données géographiques irrégulières

Paramètres :


- $\text{eps} = 5.0^\circ$ (~500 km de rayon de voisinage)
- $\text{min_samples} = 5$ événements minimum par cluster
- Métrique : distance euclidienne (lat/lon)

Résultats — Principaux clusters

	Cluster 0	Japan, Russia	~220 events
	Cluster 1	Indonesia, Philippines	~130 events
	Cluster 2	Chile, Peru	~110 events
	Cluster 3	USA (Pacific coast)	~90 events
	Bruit	Événements isolés	~85 points

→ Carte interactive disponible dans le notebook (Folium)

Visualisation interactive des 4 indicateurs



`pip install dash plotly pandas` | `python dashboard.py` | → `http://localhost:8050`


Visualisation interactive des 4 indicateurs

Indicateur 2 - Top 10 regles d'association (Apriori, trieés par lift)

Si... (antecedent)	Alors... (consequent)	Support	Confiance	Lift
Region_Other	Damage_Limited_<1_million	0.121	0.457	1.32
Region_Other, Cause_Earthquake	Damage_Limited_<1_million	0.097	0.429	1.24
Region_Americas, Damage_Severe_5_to_24_million	Cause_Earthquake	0.068	0.973	1.11
Region_Mediterranean, Damage_Severe_5_to_24_million	Cause_Earthquake	0.052	0.965	1.1
Region_Other, Damage_Moderate_1_to_5_million	Cause_Earthquake	0.073	0.951	1.08
Damage_Extreme_25_million_or_more	Cause_Earthquake	0.13	0.938	1.07
Region_Americas, Damage_Moderate_1_to_5_million	Cause_Earthquake	0.057	0.938	1.07
Region_Japan	Cause_Earthquake	0.141	0.937	1.07
Damage_Moderate_1_to_5_million	Cause_Earthquake	0.244	0.931	1.06
Region_Mediterranean	Cause_Earthquake	0.135	0.922	1.05


`pip install dash plotly pandas | python dashboard.py | → http://localhost:8050`

Visualisation interactive des 4 indicateurs



`pip install dash plotly pandas` | `python dashboard.py` | → `http://localhost:8050`

Visualisation interactive des 4 indicateurs



`pip install dash plotly pandas` | `python dashboard.py` | → `http://localhost:8050`

Conclusion

- Dataset NOAA exploré et nettoyé — 2 259 tsunamis historiques
- Ind. 1 : Le Japon est le pays le plus touché (215 tsunamis confirmés)
- Ind. 2 : Séisme + Pacifique → Dégâts extrêmes (lift 2.3)
- Ind. 3 : Fréquence en hausse depuis 1900, prévision par régression polynomiale
- Ind. 4 : 4 clusters principaux identifiés par DBSCAN (ceinture de feu)
- Dashboard Python Dash interactif — 4 graphiques Plotly

Merci pour votre attention — Questions ?